



***** Proyecto final Computación de Alto Desempeño*****

Implementación modelos para verificar pureza y calidad del agua

Autor: Juan Camilo Torres Fecha actual: 27 de mayo de 2026

Problemática

Se tiene que el tratamiento del agua debe ser indispensable para garantizar la pureza y la calidad. Uno de los elementos significativos es aplicar los conceptos de los Procesamientos de Datos en Alto Volúmen para solucionar este tipo de problemas que afectan la salud publica. El presente ejemplo tiene como propósito tener en cuenta una metodogología para aplicar el PAVD para solucionar o diagnosticar la calidad del agua en la INDIA.

Objetivo

Implementar modelos de predicción utilizando la biblioteca de aprendizaje automático MLlib PySpark, con el fin de explorar y aplicar técnicas de IA en entornos de procesamiento con alto volumen de datos.

Metodología

1. Importación de bibliotecas y levantamiento de sesión Spark sobre el clúster HPC.
2. Carga de datos desde el HDFS del clúster
(`hdfs://10.195.34.34:9000/csv/waterquality.csv`).
3. Preprocesamiento: cambio de tipos, análisis de nulos, filtrado y limpieza con PySpark SQL.
4. Análisis Exploratorio de Datos (EDA) y visualización de parámetros.
5. Cálculo del Índice WQI y clasificación de la calidad del agua.

6. Visualización geoespacial sobre el mapa de la India (GeoPandas).
7. Entrenamiento de cuatro modelos: Red Neuronal Keras, MLlib Random Forest, MLlib Gradient Boosted Trees (modelo adicional) y MLlib Regresión Lineal (baseline).
8. Evaluación y comparación con `RegressionEvaluator` de PySpark MLlib.
9. Análisis.
10. conclusiones.

Referencia de calidad de parámetros del agua: <https://www.intechopen.com/chapters/69568>

Importación de librerías para la implementación

Crear sesión de spark

Sesion creada: Calidad_Agua_Torres

Carga de datos desde Hadoop HDFS

Found 11 items

```
-rw-r--r-- 2 sistemas supergroup 977501 2026-03-10 15:27 /csv/CustomerChurn.csv
-rw-r--r-- 2 sistemas supergroup 40868 2025-07-07 15:41 /csv/Fortune500USComp
nies.csv
drwxr-xr-x - sistemas supergroup 0 2025-10-16 14:17 /csv/auxiliar
-rw-r--r-- 2 sistemas supergroup 4610348 2026-04-28 08:17 /csv/bank-full.csv
-rw-r--r-- 2 sistemas supergroup 34635 2025-09-02 13:22 /csv/jugadores.csv
-rw-r--r-- 2 sistemas supergroup 1082023 2025-09-02 13:22 /csv/resultados_futbo
l.csv
-rw-r--r-- 2 sistemas supergroup 316971 2025-06-10 09:11 /csv/stroke_pyspark.cs
v
drwxr-xr-x - sistemas supergroup 0 2025-06-18 15:36 /csv/taxi
drwxr-xr-x - sistemas supergroup 0 2026-04-23 15:56 /csv/titanic
-rw-r--r-- 2 sistemas supergroup 48036 2025-06-12 14:31 /csv/waterquality.csv
-rw-r--r-- 2 sistemas supergroup 84199 2026-04-23 17:11 /csv/winequality-red.c
sv
```

Cantidad de registros: 534

```
+-----+-----+-----+-----+-----+-----+-----+-----+
-----+-----+-----+
|STATION CODE|          LOCATIONS|      STATE|TEMP| DO| pH|CONDUCTIVITY|BOD|NITRATE_
N_NITRITE_N|FECAL_COLIFORM|TOTAL_COLIFORM|
+-----+-----+-----+-----+-----+-----+-----+-----+
-----+-----+-----+
|      1312|GODAVARI AT JAYAK...|MAHARASHTRA|29.2|6.4|8.1|          735|3.4|
2|          3|          73|
|      2177|GODAVARI RIVER NE...|MAHARASHTRA|24.5| 6| 8|          270|3.1|
2|          72|          182|
|      2182|GODAVARI RIVER AT...|MAHARASHTRA|25.8|5.5|7.8|          355|4.2|
9|          59|          133|
|      2179|GODAVARI RIVER AT...|MAHARASHTRA|24.8|5.5|7.8|          371|5.6|
3.55|          90|          283|
|      2183|GODAVARI RIVER AT...|MAHARASHTRA|25.7|5.7|7.9|          294|3.2|
2.69|          45|          132|
+-----+-----+-----+-----+-----+-----+-----+-----+
-----+-----+-----+
only showing top 5 rows
```

Análisis y preparación de datos ETL

Se presentan datos (csv) con los diferentes parámetros de los rios de la India. Cada parámetro es el promedio de los valores medidos en un período de tiempo. Los datos han sido extraídos de la web oficial de la India (RiverIndia)

- Tipos de datos: coherencia de tipo de datos, transformación
- Columnas: conocimiento de las columnas, eliminación.
- Análisis de datos nulos o imposibles: concimiento.

Columnas de los datos crudos

```
['STATION CODE',  
 'LOCATIONS',  
 'STATE',  
 'TEMP',  
 'DO',  
 'pH',  
 'CONDUCTIVITY',  
 'BOD',  
 'NITRATE_N_NITRITE_N',  
 'FECAL_COLIFORM',  
 'TOTAL_COLIFORM']
```

Descripción de cada columna

- STATION CODE: Código de estación de medida
- LOCATIONS: ubicaciones de los rios
- STATE: Estado de la india
- TEMP: Temperatura del agua en °C
- DO: Oxigeno Disuelto (mg/L). Concentraciones altas de oxigeno representa mejor calidad del agua.
- pH: Logaritmo negativo de la concentración de hidrógeno. Número adimensional para indicar la acidez del agua.
- CONDUCTIVITY: Mide la habilidad de una solución conducir corriente. El agua pura NO es conductora de corriente.
- BOD: Bacterias y otros microorganismos que utilizan sustancias orgánicas como alimento: Demanda Bioquímica de Oxigeno. Mayor cantidad de material orgánico mayor BOD.
- NITRATE_N_NITRITE_N: Nitratos/Nitritos "nitrógeno". Altas concentraciones Nitrogeno en la superficie del agua puede estimular el rápido crecimiento de algas las cuales degradan la calidad del agua (mg/L).
- FECAL_COLIFORM: Promedio de bacterias coliformes: excreciones.
- TOTAL_COLIFORM: Se eliminará pues no aporta al estudio de predicción de la calidad del agua.

Distribución de los datos

STATION CODE	
count	534
mean	2052.516853932584
stddev	755.2178560086894
min	1023
max	41

LOCATIONS	
count	534
mean	null
stddev	null
min	AHMEDABAD
max	ZUARI AT PANCHAWADI

STATE	
count	534
mean	null
stddev	null
min	ANDHRA PRADESH
max	WEST BENGAL

TEMP	
count	534
mean	25.241398865784515
stddev	3.4480130875026624
min	10.5
max	NA

D0	
count	534
mean	6.389812030075193
stddev	1.622861728733986
min	0
max	NA

pH	
count	534
mean	7.79812734082397

stddev	0.6499503911518124
min	13.2
max	9.1

summary	CONDUCTIVITY
count	534
mean	684.9761904761905
stddev	1769.3297602834873
min	100
max	NA

summary	BOD
count	534
mean	5.339772727272726
stddev	8.500503922190218
min	0.2
max	NA

summary	NITRATE_N_NITRITE_N
count	534
mean	1.3785714285714301
stddev	2.803947753154703
min	0
max	NA


summary	FECAL_COLIFORM
count	534
mean	7384.170353982301
stddev	30714.05963523712
min	0
max	NA

summary	TOTAL_COLIFORM
count	534
mean	124396.96767676767
stddev	1458407.8189939584
min	1
max	NA

Histograma de datos

Se visualiza la distribución de datos por cada columna para cada clase

Distribución de Parámetros de Calidad del Agua — Ríos de la India



Interpretación de los Histogramas de Parámetros

Cada histograma muestra la frecuencia de los valores medidos en las estaciones de monitoreo de ríos de la India. Las líneas **negra punteada** (media) y **roja punteada** (mediana) permiten identificar simetría y la influencia de valores extremos.

Variables con distribución aproximadamente normal

- **TEMP** — Temperatura concentrada entre 20–30 °C, con pico alrededor de 25 °C. La cercanía entre media y mediana indica distribución simétrica, típica de promedios estacionales.
- **DO (Oxígeno Disuelto)** — Concentrado entre 6–9 mg/L con forma de campana. La mayoría de los ríos tienen niveles aceptables de oxígeno para la vida acuática (umbral mínimo: 6 mg/L).

- **pH** — Mayoría de valores entre 7–9, con pico en ~8. Aguas mayormente neutras a ligeramente alcalinas, rango normal para ecosistemas fluviales.

Variables con distribución sesgada a la derecha (presencia de outliers)

- **CONDUCTIVITY** — El 90%+ de datos se acumula en 0–2000 $\mu\text{S}/\text{cm}$, pero hay valores extremos hasta ~25 000 $\mu\text{S}/\text{cm}$. Indica que la mayoría de los ríos son de baja mineralización, pero algunos presentan contaminación salina o industrial severa.
- **BOD (Demanda Biológica de Oxígeno)** — La mayoría de ríos tiene BOD < 10 mg/L, con outliers hasta 75 mg/L. El sesgo hacia la derecha revela focos puntuales de contaminación orgánica intensa.
- **NITRATE_N_NITRITE_N** — Concentrado en 0–5 mg/L con cola larga. Los valores altos de nitratos son indicativos de escorrentía agrícola con fertilizantes nitrogenados.
- **FECAL_COLIFORM** — El caso más extremo: la mayor parte de valores están próximos a cero, pero existen outliers que alcanzan 300 000 MPN/100 ml. Esta distribución altamente sesgada indica contaminación fecal crítica en puntos específicos, que representan un grave riesgo sanitario.

Validación de Datos Nulos

STATION_CODE LOCATIONS STATE TEMP DO pH CONDUCTIVITY BOD NITRATE_N_NITRITE_N FECAL_COLIFORM TOTAL_COLIFORM										
0	0	0	0	0	0	0	0	0	0	0

No se encuentra ningún valor nulo ni imposible basado en la salida del comando anterior

- Se procede a Graficar cada una de las dimensiones
- Se crea una vista para ser usada en las visualizaciones

En PySpark, al igual que en motores de bases de datos relacionales como PostgreSQL o MySQL, es posible crear vistas temporales sobre un DataFrame para consultarlo usando sintaxis SQL estándar.

Esta instrucción registra el DataFrame df00 como una vista temporal llamada df00_sql dentro de la sesión Spark activa. La vista no almacena datos físicamente — es simplemente una referencia nombrada al DataFrame original, análoga a una VIEW en SQL tradicional. Al ser temporal, existe únicamente durante la sesión Spark y se elimina automáticamente al finalizarla.

Se verifica la Cantidad de Valores Nulos o Imposibles


```
df01.select([F.count(F.when(F.isnan(c) | F.col(c).isNull(), c)).alias(c) for c in df01.columns]).show()
```

Aunque para este caso la eliminación de datos nulos e imposibles, no tiene ningún efecto porque no existía ninguno inicialmente, se deja como parte del pipeline en caso de que los datos cambien en un futuro y se requiera hacer nuevamente un proceso de etl que si implique algún campo inválido.

Tratamiento de Datos

Se procede a cambiar los tipos de datos

```
[('STATION CODE', 'string'),  
 ('LOCATIONS', 'string'),  
 ('STATE', 'string'),  
 ('TEMP', 'float'),  
 ('DO', 'float'),  
 ('pH', 'float'),  
 ('CONDUCTIVITY', 'float'),  
 ('BOD', 'float'),  
 ('NITRATE_N_NITRITE_N', 'float'),  
 ('FECAL_COLIFORM', 'float'),  
 ('TOTAL_COLIFORM', 'string')]
```

Se elimina la columna TOTAL_COLIFORM

```
['STATION CODE',  
 'LOCATIONS',  
 'STATE',  
 'TEMP',  
 'DO',  
 'pH',  
 'CONDUCTIVITY',  
 'BOD',  
 'NITRATE_N_NITRITE_N',  
 'FECAL_COLIFORM']
```

Creación de Tablas para Visualizar los Datos

- Se hace uso de la función LAMBDA para hacer el tratamiento/limpieza de los datos

[3.0,
72.0,
59.0,
90.0,
45.0,
131.0,
122.0,
110.0,
77.0,
22.0,
2.0,
2.0,
2.0,
2.0,
2.0,
3.0,
2.0,
27.0,
130.0,
240.0,
500.0,
130.0,
300.0,
300.0,
280.0,
240.0,
2.0,
3.0,
2.0,
48.0,
None,
3.0,
23.0,
None,
None,
None,
None,
None,
None,
None,
None,
None,
None,
None,
None,
664.0,
4000.0,
370.0,
410.0,
400.0,
2200.0,
2978.0,
2333.0,
2600.0,
15889.0,
5517.0,
5158.0,

17283.0,
18333.0,
19500.0,
1567.0,
2146.0,
2617.0,
31167.0,
17500.0,
70.0,
1190.0,
3183.0,
1600.0,
660.0,
1483.0,
6527.0,
3782.0,
1382.0,
1846.0,
1251.0,
2792.0,
1622.0,
1560.0,
2933.0,
2678.0,
1705.0,
1198.0,
1106.0,
998.0,
1220.0,
1290.0,
1846.0,
1048.0,
166358.0,
143275.0,
34392.0,
106417.0,
153917.0,
285833.0,
122417.0,
310417.0,
31417.0,
41750.0,
146.0,
2128.0,
585.0,
12418.0,
5449.0,
444.0,
3388.0,
1653.0,
1208.0,
2990.0,
15.0,
None,
149.0,
2.0,

None,
4.0,
183.0,
191.0,
171.0,
780.0,
890.0,
518.0,
792.0,
538.0,
678.0,
None,
28.0,
None,
11.0,
2.0,
2.0,
2.0,
36.0,
2.0,
7900.0,
1100.0,
9.0,
11.0,
None,
None,
None,
43546.0,
53546.0,
34818.0,
2875.0,
None,
913.0,
1073.0,
None,
716.0,
56.0,
46.0,
1099.0,
430.0,
58.0,
353.0,
310.0,
308.0,
647.0,
197.0,
11667.0,
6613.0,
15109.0,
15578.0,
18158.0,
12432.0,
22473.0,
5.0,
6.0,
11.0,

9.0,
5.0,
8.0,
8.0,
4.0,
2.0,
3.0,
81125.0,
174167.0,
5692.0,
20.0,
None,
None,
3150.0,
3580.0,
None,
None,
4.0,
None,
4.0,
13.0,
4.0,
None,
None,
None,
4.0,
None,
41.0,
None,
None,
None,
4.0,
4.0,
None,
48.0,
None,
None,
None,
4.0,
None,
13.0,
None,
4.0,
2833.0,
1258.0,
423.0,
318.0,
875.0,
465.0,
175.0,
228.0,
1280.0,
1255.0,
6048.0,
638.0,
169867.0,

4708.0,
1530.0,
None,
None,
None,
None,
None,
None,
None,
2800.0,
243500.0,
2956.0,
4942.0,
137417.0,
2164.0,
6300.0,
631.0,
2120.0,
82800.0,
11083.0,
6917.0,
593.0,
232.0,
4525.0,
203.0,
583.0,
1115.0,
1287.0,
1525.0,
697.0,
710.0,
483.0,
848.0,
581.0,
527.0,
897.0,
769.0,
532.0,
1900.0,
2460.0,
1690.0,
1350.0,
1700.0,
721.0,
500.0,
740.0,
500.0,
2000.0,
670.0,
900.0,
738.0,
1500.0,
1900.0,
1200.0,
1182.0,
1400.0,

1343.0,
3867.0,
1045.0,
5000.0,
743.0,
596.0,
None,
827.0,
600.0,
2850.0,
1450.0,
30500.0,
2020.0,
27333.0,
12167.0,
11167.0,
42500.0,
21467.0,
3167.0,
28000.0,
35000.0,
20500.0,
4.0,
9.0,
12.0,
12.0,
92.0,
4.0,
4.0,
4.0,
4.0,
16.0,
15.0,
11.0,
12.0,
31.0,
66.0,
23.0,
44.0,
156.0,
28.0,
276.0,
None,
37.0,
59.0,
37.0,
34.0,
32.0,
30.0,
19.0,
15.0,
None,
None,
None,
None,
None,


15.0,
16.0,
14.0,
14.0,
22.0,
13.0,
12.0,
15.0,
None,
None,
None,
None,
None,
None,
None,
202.0,
164.0,
52.0,
386.0,
209.0,
187.0,
251.0,
164.0,
1483.0,
992.0,
1183.0,
1033.0,
4953.0,
3243.0,
5382.0,
3428.0,
2853.0,
3355.0,
6073.0,
3478.0,
2606.0,
4573.0,
2147.0,
11633.0,
3500.0,
4995.0,
1095.0,
1286.0,
3896.0,
1940.0,
6458.0,
7592.0,
3176.0,
11210.0,
5073.0,
3205.0,
4698.0,
2638.0,
864.0,
7942.0,
None,

None,
2.0,
13.0,
19.0,
9.0,
9.0,
786.0,
None,
None,
140.0,
90.0,
110.0,
110.0,
50.0,
40.0,
39.0,
15.0,
0.0,
170.0,
82.0,
98.0,
110.0,
140.0,
170.0,
114.0,
39.0,
131.0,
103.0,
140.0,
183.0,
363.0,
152.0,
2.0,
2.0,
3.0,
47.0,
33.0,
39.0,
44.0,
59.0,
14.0,
26.0,
133.0,
113.0,
150.0,
700.0,
558.0,
796.0,
620.0,
740.0,
732.0,
71.0,
93.0,
927.0,
179.0,
143.0,

129.0,
808.0,
69.0,
55.0,
18.0,
23.0,
273.0,
150.0,
718.0,
867.0,
145.0,
58.0,
532.0,
None,
None,
None,
21.0,
2.0,
2.0,
842.0,
696.0,
21.0,
14.0,
820.0,
108.0,
7453.0,
160.0,
4428.0,
3207.0,
1666.0,
18857.0,
2864.0,
None,
5064.0,
783.0,
2568.0,
4500.0,
None,
None,
None,
None,
4.0,
4.0,
None,
None,
None,
None,
None,
None,
None,
None,
None,
30.0,
24.0,
4.0,
7.0,
7.0,

7.0,
13.0,
26.0,
8.0,
4.0,
4.0,
4.0,
3.0,
5.0,
12.0,
5.0,
8.0,
None,
None,
None,
7.0,
16.0,
12.0,
4.0,
5.0,
5.0,
5.0,
4.0,
4.0,
4.0,
4.0,
4.0,
5.0,
4.0,
4.0,
7.0,
13.0]


Grafica Los parámetros para conocer sus características: DO y PH



Interpretación: Oxígeno Disuelto (DO) y pH

- **DO (Oxígeno Disuelto):** El umbral mínimo de **6 mg/L** es el límite aceptable para sostener vida acuática (peces, macroinvertebrados). Las muestras por debajo de este umbral indican estrés para el ecosistema. Los valles en la curva pueden correlacionarse con zonas de alta contaminación orgánica (alta DBO consume el oxígeno disponible).
- **pH:** El rango óptimo de **7.0 a 8.5** (sombreado verde) corresponde a condiciones neutras a ligeramente alcalinas, propias de ecosistemas fluviales saludables. Valores inferiores a 6.5 indican acidificación (lluvias ácidas o minería); superiores a 9 señalan contaminación alcalina o eutrofización severa por algas.
- **Relación entre variables:** El DO y el pH presentan cierta correlación positiva: en aguas más alcalinas (pH alto) la fotosíntesis de algas produce oxígeno, mientras que en aguas contaminadas ambas variables tienden a deteriorarse simultáneamente.
- **Ejes independientes:** Se usan ejes Y separados (izquierdo para DO, derecho para pH) ya que las unidades y escalas difieren.

Grafica Los parámetros para conocer sus características: BOD y Nitrogenos




Interpretación: DBO (Demanda Biológica de Oxígeno) y Nitratos/Nitritos

- **DBO:** Mide la cantidad de oxígeno que los microorganismos consumen al descomponer materia orgánica. Valores por encima de **3 mg/L** indican contaminación orgánica moderada; por encima de **6 mg/L** la contaminación es severa. Los picos corresponden a puntos de descarga industrial o agrícola con alta carga orgánica.
- **Nitratos + Nitritos:** Nutrientes inorgánicos nitrogenados cuyo exceso provoca **eutrofización**: proliferación de algas, reducción de oxígeno disuelto y pérdida de biodiversidad. Concentraciones por encima de **20 mg/L** señalan contaminación moderada, generalmente asociada a escorrentía agrícola con fertilizantes nitrogenados o descarga de aguas residuales urbanas.

- **Escalas independientes:** Ambas variables se grafican en ejes Y separados para permitir la visualización simultánea de sus fluctuaciones, independientemente de las diferencias en su rango de valores.

Grafica Los parámetros para conocer sus características: FC y Conductividad



Interpretación: Conductividad y Coliformes Fecales

- **Conductividad:** Mide la capacidad del agua para conducir electricidad, indicando la presencia de sales e iones disueltos. Valores por encima de **300 $\mu\text{S/cm}$** pueden señalar mineralización excesiva, contaminación industrial o intrusión salina. Conductividades muy elevadas pueden ser tóxicas para organismos acuáticos sensibles.
- **Coliformes Fecales:** Son el indicador microbiológico más directo de contaminación fecal (humana o animal). Los picos extremos (miles o decenas de miles de MPN/100 ml) representan un **riesgo sanitario grave** e indican descarga directa de aguas residuales sin tratar a los ríos. El umbral de riesgo alto está establecido en **500 MPN/100 ml** para cuerpos de agua recreativos.
- **Escalas independientes:** Dado que la conductividad y los coliformes fecales operan en magnitudes muy diferentes ($\mu\text{S/cm}$ vs. MPN/100 ml), se utilizan ejes Y independientes (izquierdo y derecho) para que ambas variables sean legibles en la misma gráfica sin compresión visual.

Función definida por el usuario para definir el rango de calidad de agua según el pH

Se crea la columna para los rangos del parámetro (Según

<https://www.intechopen.com/chapters/69568>)

Función definida por el usuario para definir el rango de la calidad del agua según DO

Función definida por el usuario para definir el rango de la calidad del agua según COND

Función definida por el usuario para definir el rango de la calidad del agua según BOD

- Función definida por el usuario para definir el rango de la calidad del agua según NITRATE_N_NITRITE_N
 - 100: Agua Dulce
 - 80: Agua Moderada
 - 60: Agua Dura
 - 40: Agua muy Dura
- Función definida por el usuario para definir el rango de la calidad del agua según el Material Fecal
 - 100: Agua Dulce
 - 80: Agua Moderada
 - 60: Agua Dura
 - 40: Agua muy Dura

Inspeccionar los datos en df02

El objeto dataframe df02, contiene hasta ahora todos los calculos y registros sobre los rangos de calidad del agua

STATION CODE	LOCATIONS	STATE	TEMP	DO	pH	CONDUCTIVITY	BOD	NITRATE	N_NITRITE_N	FECAL_COLIFORM	qrPH	qrDO	qrCOND	qrBOD	qrNN	qrFecal	wpH	wDO	wCOND	wBOD	wNN	wFecal
1312	GODAVARI AT JAYAK...	MAHARASHTRA	29.2	6.4	8.1	735.0	3.4			3.0	100	100	0	80	100	100	16.5	28.1	0.0	0.72	2.8	2
2.0																						
8.1																						
2177	GODAVARI RIVER NE...	MAHARASHTRA	24.5	6.0	8.0	270.0	3.1			72.0	100	100	40	80	100	60	16.5	28.1	9.36	0.72	2.8	16.
2.0																						
86																						
2182	GODAVARI RIVER AT...	MAHARASHTRA	25.8	5.5	7.8	355.0	4.2			59.0	100	80	0	80	100	60	16.5	22.48	0.0	0.72	2.8	16.
9.0																						
86																						
2179	GODAVARI RIVER AT...	MAHARASHTRA	24.8	5.5	7.8	371.0	5.6			90.0	100	80	0	80	100	60	16.5	22.48	0.0	0.72	2.8	1
3.55																						
6.86																						
2183	GODAVARI RIVER AT...	MAHARASHTRA	25.7	5.7	7.9	294.0	3.2			45.0	100	80	40	80	100	80	16.5	22.48	9.36	0.72	2.8	2
2.69																						
2.48																						
2181	GODAVARI RIVER AT...	MAHARASHTRA	25.0	4.5	7.5	513.0	12.6			131.0	100	60	0	60	100	60	16.5	16.86	0.0	0.54	2.8	16.
2.3																						
86																						
2180	GODAVARI RIVER NE...	MAHARASHTRA	24.8	5.2	7.7	475.0	10.3			122.0	100	80	0	60	100	60	16.5	22.48	0.0	0.54	2.8	16.
1.9																						
86																						
1096	GODAVARI AT PANCH...	MAHARASHTRA	26.3	5.6	7.7	385.0	3.8			110.0	100	80	0	80	100	60	16.5	22.48	0.0	0.72	2.8	16.
1.0																						
86																						
1211	GODAVARI AT NASIK...	MAHARASHTRA	26.5	5.2	7.8	410.0	5.2			77.0	100	80	0	80	100	60	16.5	22.48	0.0	0.72	2.8	16.
1.5																						
86																						
1095	GODAVARI AT U/S O...	MAHARASHTRA	26.0	6.5	7.8	178.0	2.5			22.0	100	100	60	100	100	80	16.5	28.1	14.04	0.9	2.8	2
1.99																						
2.48																						

only showing top 10 rows


```
['STATION CODE',  
 'LOCATIONS',  
 'STATE',  
 'TEMP',  
 'DO',  
 'pH',  
 'CONDUCTIVITY',  
 'BOD',  
 'NITRATE_N_NITRITE_N',  
 'FECAL_COLIFORM',  
 'qrPH',  
 'qrDO',  
 'qrCOND',  
 'qrBOD',  
 'qrNN',  
 'qrFecal',  
 'wpH',  
 'wDO',  
 'wCOND',  
 'wBOD',  
 'wNN',  
 'wFecal']
```

Calculo del Índice de Calidad del Agua

- Se crea la columna WQI: representa el índice de calidad, pero la NOTA A RESALTAR es que según la literatura, son muy pocos datos para que refleje un valor confiable. Es decir, que como un estudio ejemplo, NO ES UNA GUIA A TENER EN CUENTA PARA CALIDAD DE AGUA

STATION CODE		LOCATIONS				STATE	TEMP	DO	pH	CONDUCTIVITY		BOD	NITRATE	
_N	NITRITE_N	FECAL_COLIFORM	qrPH	qrDO	qrCOND	qrBOD	qrNN	qrFecal	wpH	wDO	wCOND	wBOD		
wNN	wFecal	WQI												
1312	GODAVARI AT JAYAK...	MAHARASHTRA	29.2	6.4	8.1				735.0	3.4				
2.0	3.0	100	100	0	80	100	100	16.5	28.1	0.0	0.72	2.8	2	
8.1	76.22													
2177	GODAVARI RIVER NE...	MAHARASHTRA	24.5	6.0	8.0				270.0	3.1				
2.0	72.0	100	100	40	80	100	60	16.5	28.1	9.36	0.72	2.8	16.	
86	74.34													
2182	GODAVARI RIVER AT...	MAHARASHTRA	25.8	5.5	7.8				355.0	4.2				
9.0	59.0	100	80	0	80	100	60	16.5	22.48	0.0	0.72	2.8	16.	
86	59.36													
2179	GODAVARI RIVER AT...	MAHARASHTRA	24.8	5.5	7.8				371.0	5.6				
3.55	90.0	100	80	0	80	100	60	16.5	22.48	0.0	0.72	2.8	1	
6.86	59.36													
2183	GODAVARI RIVER AT...	MAHARASHTRA	25.7	5.7	7.9				294.0	3.2				
2.69	45.0	100	80	40	80	100	80	16.5	22.48	9.36	0.72	2.8	2	
2.48	74.34													
2181	GODAVARI RIVER AT...	MAHARASHTRA	25.0	4.5	7.5				513.0	12.6				
2.3	131.0	100	60	0	60	100	60	16.5	16.86	0.0	0.54	2.8	16.	
86	53.56													
2180	GODAVARI RIVER NE...	MAHARASHTRA	24.8	5.2	7.7				475.0	10.3				
1.9	122.0	100	80	0	60	100	60	16.5	22.48	0.0	0.54	2.8	16.	
86	59.18													
1096	GODAVARI AT PANCH...	MAHARASHTRA	26.3	5.6	7.7				385.0	3.8				
1.0	110.0	100	80	0	80	100	60	16.5	22.48	0.0	0.72	2.8	16.	
86	59.36													
1211	GODAVARI AT NASIK...	MAHARASHTRA	26.5	5.2	7.8				410.0	5.2				
1.5	77.0	100	80	0	80	100	60	16.5	22.48	0.0	0.72	2.8	16.	
86	59.36													
1095	GODAVARI AT U/S O...	MAHARASHTRA	26.0	6.5	7.8				178.0	2.5				
1.99	22.0	100	100	60	100	100	80	16.5	28.1	14.04	0.9	2.8	2	
2.48	84.82													

only showing top 10 rows

Intervalos de Índices para WQI

- Excelente: agua dulce **WQI = [0.0 , 25.0]**
- Buena: agua moderada **WQI = (25.0 , 50.0]**
- Baja: agua dura **WQI = (50.0 , 75.0]**
- Muy_Baja: agua muy dura **WQI = (75.0 , 100.0]**
- Inadecuada: agua residual **WQI > 100**

STATION CODE		LOCATIONS				STATE	TEMP	DO	pH	CONDUCTIVITY		BOD	NITRATE	
_N_NITRITE_N		FECAL_COLIFORM		qrPH	qrDO	qrCOND	qrBOD	qrNN	qrFecal	wpH	wDO	wCOND	wBOD	
wNN wFecal		WQI		CALIDAD										

VISUALIZACIÓN DE ESTADOS DE LA INDIA

- Se visualizan los estados sobre los datos obtenidos de la Calidad del Agua, es decir, las etiquetas de calidad de agua

• Impresión de nombre de regiones sobre el mapa

```
['WEST BENGAL', 'GOA', 'CHHATTISGARH', 'RAJASTHAN', 'DELHI', 'HIMACHAL PRADESH', 'GUJARAT', 'BIHAR', 'KARNATAKA', 'UTTAR PRADESH', 'MADHYA PRADESH', 'MAHARASHTRA', 'PUNJAB', 'UTTARAKHAND', 'TAMILNADU', 'ANDHRA PRADESH', 'KERALA', 'ASSAM']
```

Se cargan los datos de los mapas disponibles

Los ficheros comprimidos ".dbf", ".prj", ".shp", ".shx" deben estar juntos en una carpeta


```
<class 'geopandas.geodataframe.GeoDataFrame'>
array(['Andaman Nicobar Island', 'Arunachal Pradesh', 'Assam', 'Bihar',
      'Chandigarh', 'Chhattisgarh', 'Dadra Nagar Haveli', 'Daman Diu',
      'Goa', 'Gujarat', 'Haryana', 'Himachal Pradesh', 'Jammu Kashmir',
      'Jharkhand', 'Karnataka', 'Kerala', 'Lakshadweep',
      'Madhya Pradesh', 'Maharashtra', 'Manipur', 'Meghalaya', 'Mizoram',
      'Nagaland', 'Delhi', 'Puducherry', 'Punjab', 'Rajasthan', 'Sikkim',
      'Tamil Nadu', 'Telangana', 'Tripura', 'Uttar Pradesh',
      'Uttarakhand', 'West Bengal', 'Odisha', 'Andhra Pradesh'],
      dtype=object)
```

Se hacen los cambios correspondientes, a continuación, para que coincidan con los nombres iniciales nombre de "st_nm" que sea "STATE" Se combinan es formato pandas para pintar el mapa
Se garantizan los puntos dentro del mapa Se eliminan los duplicados

```
+-----+-----+-----+-----+-----+-----+-----+-----+-----+
-----+-----+-----+-----+-----+-----+-----+-----+-----+
---+-----+-----+
|STATION CODE|      LOCATIONS|      STATE|TEMP| DO| pH|CONDUCTIVITY|BOD|NITRATE_
N_NITRITE_N|FECAL_COLIFORM|qrPH|qrDO|qrCOND|qrBOD|qrNN|qrFecal| wpH|  wDO|wCOND|wBOD|
wNN|wFecal|  WQI| CALIDAD|
+-----+-----+-----+-----+-----+-----+-----+-----+-----+
-----+-----+-----+-----+-----+-----+-----+-----+-----+
---+-----+-----+
|          1312|GODAVARI AT JAYAK...|Maharashtra|29.2|6.4|8.1|          735.0|3.4|
2.0|          3.0| 100| 100|          0|   80| 100|          100|16.5| 28.1|   0.0|0.72|2.8|  2
8.1|76.22|Muy_Baja|
|          2177|GODAVARI RIVER NE...|Maharashtra|24.5|6.0|8.0|          270.0|3.1|
2.0|          72.0| 100| 100|         40|   80| 100|          60|16.5| 28.1|  9.36|0.72|2.8| 16.
86|74.34|    Baja|
|          2182|GODAVARI RIVER AT...|Maharashtra|25.8|5.5|7.8|          355.0|4.2|
9.0|          59.0| 100|  80|          0|   80| 100|          60|16.5|22.48|   0.0|0.72|2.8| 16.
86|59.36|    Baja|
|          2179|GODAVARI RIVER AT...|Maharashtra|24.8|5.5|7.8|          371.0|5.6|
3.55|          90.0| 100|  80|          0|   80| 100|          60|16.5|22.48|   0.0|0.72|2.8|  1
6.86|59.36|    Baja|
|          2183|GODAVARI RIVER AT...|Maharashtra|25.7|5.7|7.9|          294.0|3.2|
2.69|          45.0| 100|  80|         40|   80| 100|          80|16.5|22.48|  9.36|0.72|2.8|  2
2.48|74.34|    Baja|
+-----+-----+-----+-----+-----+-----+-----+-----+-----+
-----+-----+-----+-----+-----+-----+-----+-----+-----+
---+-----+-----+
only showing top 5 rows
```

Se pinta el mapa inicial

Mapa de la India — División por Estados



Interpretación: Mapa Geográfico Inicial de la India

Este mapa muestra la división político-administrativa de la India por estados y territorios de unión. El fondo azul representa cuerpos de agua circundantes, mientras que el relleno verde claro con bordes oscuros facilita la diferenciación entre estados.

- **Cobertura geográfica:** El dataset abarca la mayor parte del territorio indio: estados del norte (Uttar Pradesh, Bihar), el sur (Tamil Nadu, Kerala, Karnataka), las zonas costeras del este y del oeste, y los estados del noreste.
- **Propósito:** Este mapa inicial sirve como referencia geográfica base. Las visualizaciones posteriores superpondrán el Índice de Calidad del Agua (WQI) sobre esta misma estructura espacial.
- **Contexto hídrico:** India cuenta con una extensa red fluvial que incluye los ríos Ganges, Brahmaputra, Krishna, Godavari, Cauvery y Narmada, entre los principales. La calidad varía significativamente según densidad poblacional, actividad industrial y prácticas agrícolas de cada cuenca.

-Se requiere superponer las etiquetas de los estados de la India en el MAPA

WARNING: Ignoring invalid distribution ~eopandas (/opt/jupyterhub/lib/python3.12/site-packages)

Requirement already satisfied: adjustText in /opt/jupyterhub/lib/python3.12/site-packages (1.3.0)

Requirement already satisfied: numpy in /opt/jupyterhub/lib/python3.12/site-packages (from adjustText) (2.3.0)

Requirement already satisfied: matplotlib in /opt/jupyterhub/lib/python3.12/site-packages (from adjustText) (3.10.7)

Requirement already satisfied: scipy in /opt/jupyterhub/lib/python3.12/site-packages (from adjustText) (1.16.3)

Requirement already satisfied: contourpy>=1.0.1 in /opt/jupyterhub/lib/python3.12/site-packages (from matplotlib->adjustText) (1.3.3)

Requirement already satisfied: cyclor>=0.10 in /opt/jupyterhub/lib/python3.12/site-packages (from matplotlib->adjustText) (0.12.1)

Requirement already satisfied: fonttools>=4.22.0 in /opt/jupyterhub/lib/python3.12/site-packages (from matplotlib->adjustText) (4.60.1)

Requirement already satisfied: kiwisolver>=1.3.1 in /opt/jupyterhub/lib/python3.12/site-packages (from matplotlib->adjustText) (1.4.9)

Requirement already satisfied: packaging>=20.0 in /opt/jupyterhub/lib/python3.12/site-packages (from matplotlib->adjustText) (25.0)

Requirement already satisfied: pillow>=8 in /opt/jupyterhub/lib/python3.12/site-packages (from matplotlib->adjustText) (12.0.0)

Requirement already satisfied: pyparsing>=3 in /opt/jupyterhub/lib/python3.12/site-packages (from matplotlib->adjustText) (3.2.5)

Requirement already satisfied: python-dateutil>=2.7 in /opt/jupyterhub/lib/python3.12/site-packages (from matplotlib->adjustText) (2.9.0.post0)

Requirement already satisfied: six>=1.5 in /opt/jupyterhub/lib/python3.12/site-packages (from python-dateutil>=2.7->matplotlib->adjustText) (1.17.0)

WARNING: Ignoring invalid distribution ~eopandas (/opt/jupyterhub/lib/python3.12/site-packages)

WARNING: Ignoring invalid distribution ~eopandas (/opt/jupyterhub/lib/python3.12/site-packages)

[notice] A new release of pip is available: 25.1.1 -> 26.1.1

[notice] To update, run: python -m pip install --upgrade pip

WARNING: Ignoring invalid distribution ~eopandas (/opt/jupyterhub/lib/python3.12/site-packages)

Requirement already satisfied: mapclassify>=2.4.0 in /opt/jupyterhub/lib/python3.12/site-packages (2.10.0)

Requirement already satisfied: networkx>=3.2 in /opt/jupyterhub/lib/python3.12/site-packages (from mapclassify>=2.4.0) (3.6.1)

Requirement already satisfied: numpy>=1.26 in /opt/jupyterhub/lib/python3.12/site-packages (from mapclassify>=2.4.0) (2.3.0)

Requirement already satisfied: pandas>=2.1 in /opt/jupyterhub/lib/python3.12/site-packages (from mapclassify>=2.4.0) (2.3.0)

Requirement already satisfied: scikit-learn>=1.4 in /opt/jupyterhub/lib/python3.12/site-packages (from mapclassify>=2.4.0) (1.8.0)

Requirement already satisfied: scipy>=1.12 in /opt/jupyterhub/lib/python3.12/site-packages (from mapclassify>=2.4.0) (1.16.3)

Requirement already satisfied: python-dateutil>=2.8.2 in /opt/jupyterhub/lib/python3.12/site-packages (from pandas>=2.1->mapclassify>=2.4.0) (2.9.0.post0)

Requirement already satisfied: pytz>=2020.1 in /opt/jupyterhub/lib/python3.12/site-packages (from pandas>=2.1->mapclassify>=2.4.0) (2025.2)

Requirement already satisfied: tzdata>=2022.7 in /opt/jupyterhub/lib/python3.12/site-packages (from pandas>=2.1->mapclassify>=2.4.0) (2025.2)

Requirement already satisfied: six>=1.5 in /opt/jupyterhub/lib/python3.12/site-packages (from python-dateutil>=2.8.2->pandas>=2.1->mapclassify>=2.4.0) (1.17.0)

Requirement already satisfied: joblib>=1.3.0 in /opt/jupyterhub/lib/python3.12/site-packages (from scikit-learn>=1.4->mapclassify>=2.4.0) (1.5.3)


Requirement already satisfied: threadpoolctl>=3.2.0 in /opt/jupyterhub/lib/python3.12/site-packages (from scikit-learn>=1.4->mapclassify>=2.4.0) (3.6.0)

WARNING: Ignoring invalid distribution ~eopandas (/opt/jupyterhub/lib/python3.12/site-packages)

WARNING: Ignoring invalid distribution ~eopandas (/opt/jupyterhub/lib/python3.12/site-packages)

[notice] A new release of pip is available: 25.1.1 -> 26.1.1

[notice] To update, run: python -m pip install --upgrade pip




Interpretación: Mapa del Índice de Calidad del Agua (WQI) por Estado

- **Escala de color (RdYlGn_r):** Los colores más rojos indican WQI más alto y, por ende, **peor calidad del agua**. Los tonos verdes señalan mejor calidad relativa. El esquema de clasificación divide el índice en cuatro rangos: 0–25 (Excelente), 25–50 (Buena), 50–75 (Baja) y 75–100 (Muy Baja).

- **Distribución geográfica:** Los estados con mayor actividad industrial y densidad poblacional, especialmente en la cuenca del Ganges (norte de la India), tienden a presentar valores WQI más elevados.
- **Anotaciones numéricas:** El valor WQI promedio de cada estado está superpuesto sobre el mapa para facilitar la comparación directa entre regiones sin necesidad de consultar la leyenda.
- **Estados sin datos:** Las regiones en gris claro no cuentan con estaciones de monitoreo en el dataset, lo que puede sesgar la interpretación geográfica total.

Histograma de WQI por Estado



Interpretación: Índice WQI Promedio por Estado

- **Estados con mejor calidad (WQI bajo — verde):** Presentan predominancia de agua dulce con bajos niveles de contaminantes. Puede asociarse con menor densidad industrial, mejor cobertura forestal o buenas prácticas de gestión ambiental.
- **Estados con calidad crítica (WQI alto — rojo):** Requieren atención prioritaria en políticas de saneamiento y control de contaminación industrial y agrícola. El umbral de **75** marca la frontera hacia agua de muy baja calidad.
- **Líneas de referencia verticales:**

- Verde oscuro (25): límite de agua *Excelente*
- Naranja (50): límite de agua *Buena*
- Rojo (75): límite de agua *Baja*
- **Escala de color (barras):** El degradado del verde al rojo visualiza directamente la gravedad relativa, facilitando la identificación inmediata de prioridades de intervención.

Creación de Modelo: Calidad de Agua en la India

- Se requiere predecir el parámetro WQI
- Se crea un DF en pandas, un vector para manipular a través de numpy las columnas de calidad: "Rangos de Calidad"
- Se importa Scikit-Learn, para separar los datos (Entrenamiento y Prueba)
- Se importa Keras Sequential Layers Dense
- Se inicializa el modelo, y se añaden las capas
- Se compila el modelo con el optimizador ADAM junto con la función de pérdida de error cuadrático
- Se realiza el experimento sobre los datos de entrenamiento
- Se realiza la evaluación sobre los datos de prueba; para la selección del modelo.

```
[ 'STATION CODE',
  'LOCATIONS',
  'STATE',
  'TEMP',
  'DO',
  'pH',
  'CONDUCTIVITY',
  'BOD',
  'NITRATE_N_NITRITE_N',
  'FECAL_COLIFORM',
  'qrPH',
  'qrDO',
  'qrCOND',
  'qrBOD',
  'qrNN',
  'qrFecal',
  'wpH',
  'wDO',
  'wCOND',
  'wBOD',
  'wNN',
  'wFecal',
  'WQI',
  'CALIDAD']
```

```

+-----+
|qrPH|qrDO|qrCOND|qrBOD|qrNN|qrFecal|
+-----+
| 100| 100|    0|   80| 100|   100|
| 100| 100|   40|   80| 100|    60|
| 100|  80|    0|   80| 100|    60|
| 100|  80|    0|   80| 100|    60|
| 100|  80|   40|   80| 100|    80|
+-----+

```

only showing top 5 rows

```

+-----+
|  WQI|
+-----+
|76.22|
|74.34|
|59.36|
|59.36|
|74.34|
+-----+

```

only showing top 5 rows

Cantidad de datos totales: (534, 24)
 Cantidad de datos Entrenamiento: (427, 6)
 Cantidad de datos Prueba: (107, 6)
 Cantidad de datos Predicción del Entrenamiento: (427, 1)
 Cantidad de datos Predicción de Prueba: (107, 1)

Model: "sequential_2"

Layer (type)	Output Shape	Param #
dense_8 (Dense)	(None, 350)	2,450
dense_9 (Dense)	(None, 350)	122,850
dense_10 (Dense)	(None, 350)	122,850
dense_11 (Dense)	(None, 1)	351

Total params: 248,501 (970.71 KB)
 Trainable params: 248,501 (970.71 KB)
 Non-trainable params: 0 (0.00 B)

Epoch 1/200
6/6  1s 4ms/step - loss: 1102.0815 - mse: 1102.0815
Epoch 2/200
6/6  0s 3ms/step - loss: 153.3025 - mse: 153.3025
Epoch 3/200
6/6  0s 4ms/step - loss: 70.9232 - mse: 70.9232
Epoch 4/200
6/6  0s 4ms/step - loss: 35.6967 - mse: 35.6967
Epoch 5/200
6/6  0s 3ms/step - loss: 18.3059 - mse: 18.3059
Epoch 6/200
6/6  0s 4ms/step - loss: 8.6750 - mse: 8.6750
Epoch 7/200
6/6  0s 4ms/step - loss: 6.2677 - mse: 6.2677
Epoch 8/200
6/6  0s 4ms/step - loss: 3.2756 - mse: 3.2756
Epoch 9/200
6/6  0s 4ms/step - loss: 1.8102 - mse: 1.8102
Epoch 10/200
6/6  0s 3ms/step - loss: 0.9468 - mse: 0.9468
Epoch 11/200
6/6  0s 4ms/step - loss: 0.4430 - mse: 0.4430
Epoch 12/200
6/6  0s 3ms/step - loss: 0.3915 - mse: 0.3915
Epoch 13/200
6/6  0s 3ms/step - loss: 0.1934 - mse: 0.1934
Epoch 14/200
6/6  0s 4ms/step - loss: 0.1525 - mse: 0.1525
Epoch 15/200
6/6  0s 4ms/step - loss: 0.1032 - mse: 0.1032
Epoch 16/200
6/6  0s 3ms/step - loss: 0.0819 - mse: 0.0819
Epoch 17/200
6/6  0s 3ms/step - loss: 0.0660 - mse: 0.0660
Epoch 18/200
6/6  0s 3ms/step - loss: 0.0572 - mse: 0.0572
Epoch 19/200
6/6  0s 3ms/step - loss: 0.0490 - mse: 0.0490
Epoch 20/200
6/6  0s 3ms/step - loss: 0.0449 - mse: 0.0449
Epoch 21/200
6/6  0s 3ms/step - loss: 0.0413 - mse: 0.0413
Epoch 22/200
6/6  0s 3ms/step - loss: 0.0397 - mse: 0.0397
Epoch 23/200
6/6  0s 3ms/step - loss: 0.0327 - mse: 0.0327
Epoch 24/200
6/6  0s 3ms/step - loss: 0.0304 - mse: 0.0304
Epoch 25/200
6/6  0s 3ms/step - loss: 0.0271 - mse: 0.0271
Epoch 26/200
6/6  0s 3ms/step - loss: 0.0245 - mse: 0.0245
Epoch 27/200
6/6  0s 3ms/step - loss: 0.0225 - mse: 0.0225
Epoch 28/200

6/6  0s 3ms/step - loss: 0.0209 - mse: 0.0209
Epoch 29/200

6/6  0s 3ms/step - loss: 0.0195 - mse: 0.0195
Epoch 30/200

6/6  0s 3ms/step - loss: 0.0183 - mse: 0.0183
Epoch 31/200

6/6  0s 3ms/step - loss: 0.0165 - mse: 0.0165
Epoch 32/200

6/6  0s 3ms/step - loss: 0.0159 - mse: 0.0159
Epoch 33/200

6/6  0s 3ms/step - loss: 0.0148 - mse: 0.0148
Epoch 34/200

6/6  0s 3ms/step - loss: 0.0147 - mse: 0.0147
Epoch 35/200

6/6  0s 3ms/step - loss: 0.0138 - mse: 0.0138
Epoch 36/200

6/6  0s 3ms/step - loss: 0.0125 - mse: 0.0125
Epoch 37/200

6/6  0s 3ms/step - loss: 0.0120 - mse: 0.0120
Epoch 38/200

6/6  0s 3ms/step - loss: 0.0119 - mse: 0.0119
Epoch 39/200

6/6  0s 3ms/step - loss: 0.0112 - mse: 0.0112
Epoch 40/200

6/6  0s 3ms/step - loss: 0.0110 - mse: 0.0110
Epoch 41/200

6/6  0s 4ms/step - loss: 0.0102 - mse: 0.0102
Epoch 42/200

6/6  0s 3ms/step - loss: 0.0096 - mse: 0.0096
Epoch 43/200

6/6  0s 3ms/step - loss: 0.0106 - mse: 0.0106
Epoch 44/200

6/6  0s 3ms/step - loss: 0.0096 - mse: 0.0096
Epoch 45/200

6/6  0s 3ms/step - loss: 0.0086 - mse: 0.0086
Epoch 46/200

6/6  0s 3ms/step - loss: 0.0084 - mse: 0.0084
Epoch 47/200

6/6  0s 3ms/step - loss: 0.0079 - mse: 0.0079
Epoch 48/200

6/6  0s 3ms/step - loss: 0.0079 - mse: 0.0079
Epoch 49/200

6/6  0s 3ms/step - loss: 0.0075 - mse: 0.0075
Epoch 50/200

6/6  0s 3ms/step - loss: 0.0072 - mse: 0.0072
Epoch 51/200

6/6  0s 3ms/step - loss: 0.0070 - mse: 0.0070
Epoch 52/200

6/6  0s 3ms/step - loss: 0.0079 - mse: 0.0079
Epoch 53/200

6/6  0s 3ms/step - loss: 0.0083 - mse: 0.0083
Epoch 54/200

6/6  0s 3ms/step - loss: 0.0071 - mse: 0.0071
Epoch 55/200

6/6  0s 3ms/step - loss: 0.0067 - mse: 0.0067
Epoch 56/200

6/6  0s 3ms/step - loss: 0.0059 - mse: 0.0059
Epoch 57/200

6/6  0s 3ms/step - loss: 0.0065 - mse: 0.0065
Epoch 58/200

6/6  0s 3ms/step - loss: 0.0056 - mse: 0.0056
Epoch 59/200

6/6  0s 3ms/step - loss: 0.0055 - mse: 0.0055
Epoch 60/200

6/6  0s 3ms/step - loss: 0.0055 - mse: 0.0055
Epoch 61/200

6/6  0s 3ms/step - loss: 0.0051 - mse: 0.0051
Epoch 62/200

6/6  0s 3ms/step - loss: 0.0052 - mse: 0.0052
Epoch 63/200

6/6  0s 3ms/step - loss: 0.0052 - mse: 0.0052
Epoch 64/200

6/6  0s 3ms/step - loss: 0.0057 - mse: 0.0057
Epoch 65/200

6/6  0s 3ms/step - loss: 0.0058 - mse: 0.0058
Epoch 66/200

6/6  0s 3ms/step - loss: 0.0050 - mse: 0.0050
Epoch 67/200

6/6  0s 3ms/step - loss: 0.0044 - mse: 0.0044
Epoch 68/200

6/6  0s 3ms/step - loss: 0.0044 - mse: 0.0044
Epoch 69/200

6/6  0s 3ms/step - loss: 0.0049 - mse: 0.0049
Epoch 70/200

6/6  0s 3ms/step - loss: 0.0050 - mse: 0.0050
Epoch 71/200

6/6  0s 3ms/step - loss: 0.0038 - mse: 0.0038
Epoch 72/200

6/6  0s 3ms/step - loss: 0.0040 - mse: 0.0040
Epoch 73/200

6/6  0s 3ms/step - loss: 0.0041 - mse: 0.0041
Epoch 74/200

6/6  0s 3ms/step - loss: 0.0038 - mse: 0.0038
Epoch 75/200

6/6  0s 3ms/step - loss: 0.0036 - mse: 0.0036
Epoch 76/200

6/6  0s 3ms/step - loss: 0.0041 - mse: 0.0041
Epoch 77/200

6/6  0s 3ms/step - loss: 0.0034 - mse: 0.0034
Epoch 78/200

6/6  0s 3ms/step - loss: 0.0034 - mse: 0.0034
Epoch 79/200

6/6  0s 3ms/step - loss: 0.0034 - mse: 0.0034
Epoch 80/200

6/6  0s 3ms/step - loss: 0.0033 - mse: 0.0033
Epoch 81/200

6/6  0s 3ms/step - loss: 0.0032 - mse: 0.0032
Epoch 82/200

6/6  0s 3ms/step - loss: 0.0030 - mse: 0.0030
Epoch 83/200

6/6  0s 3ms/step - loss: 0.0031 - mse: 0.0031
Epoch 84/200

6/6  0s 3ms/step - loss: 0.0039 - mse: 0.0039
Epoch 85/200

6/6  0s 3ms/step - loss: 0.0044 - mse: 0.0044
Epoch 86/200

6/6  0s 3ms/step - loss: 0.0039 - mse: 0.0039
Epoch 87/200

6/6  0s 3ms/step - loss: 0.0035 - mse: 0.0035
Epoch 88/200

6/6  0s 3ms/step - loss: 0.0029 - mse: 0.0029
Epoch 89/200

6/6  0s 3ms/step - loss: 0.0031 - mse: 0.0031
Epoch 90/200

6/6  0s 3ms/step - loss: 0.0030 - mse: 0.0030
Epoch 91/200

6/6  0s 3ms/step - loss: 0.0031 - mse: 0.0031
Epoch 92/200

6/6  0s 3ms/step - loss: 0.0033 - mse: 0.0033
Epoch 93/200

6/6  0s 3ms/step - loss: 0.0027 - mse: 0.0027
Epoch 94/200

6/6  0s 3ms/step - loss: 0.0027 - mse: 0.0027
Epoch 95/200

6/6  0s 3ms/step - loss: 0.0028 - mse: 0.0028
Epoch 96/200

6/6  0s 3ms/step - loss: 0.0026 - mse: 0.0026
Epoch 97/200

6/6  0s 3ms/step - loss: 0.0027 - mse: 0.0027
Epoch 98/200

6/6  0s 3ms/step - loss: 0.0024 - mse: 0.0024
Epoch 99/200

6/6  0s 3ms/step - loss: 0.0027 - mse: 0.0027
Epoch 100/200

6/6  0s 3ms/step - loss: 0.0029 - mse: 0.0029
Epoch 101/200

6/6  0s 3ms/step - loss: 0.0040 - mse: 0.0040
Epoch 102/200

6/6  0s 3ms/step - loss: 0.0033 - mse: 0.0033
Epoch 103/200

6/6  0s 3ms/step - loss: 0.0023 - mse: 0.0023
Epoch 104/200

6/6  0s 3ms/step - loss: 0.0024 - mse: 0.0024
Epoch 105/200

6/6  0s 3ms/step - loss: 0.0022 - mse: 0.0022
Epoch 106/200

6/6  0s 3ms/step - loss: 0.0020 - mse: 0.0020
Epoch 107/200

6/6  0s 3ms/step - loss: 0.0020 - mse: 0.0020
Epoch 108/200

6/6  0s 3ms/step - loss: 0.0024 - mse: 0.0024
Epoch 109/200

6/6  0s 3ms/step - loss: 0.0022 - mse: 0.0022
Epoch 110/200

6/6  0s 3ms/step - loss: 0.0028 - mse: 0.0028
Epoch 111/200

6/6  0s 3ms/step - loss: 0.0028 - mse: 0.0028
Epoch 112/200

6/6  0s 3ms/step - loss: 0.0021 - mse: 0.0021
Epoch 113/200

6/6  0s 3ms/step - loss: 0.0021 - mse: 0.0021
Epoch 114/200

6/6  0s 3ms/step - loss: 0.0020 - mse: 0.0020
Epoch 115/200

6/6  0s 3ms/step - loss: 0.0020 - mse: 0.0020
Epoch 116/200

6/6  0s 3ms/step - loss: 0.0020 - mse: 0.0020
Epoch 117/200

6/6  0s 3ms/step - loss: 0.0017 - mse: 0.0017
Epoch 118/200

6/6  0s 3ms/step - loss: 0.0020 - mse: 0.0020
Epoch 119/200

6/6  0s 3ms/step - loss: 0.0018 - mse: 0.0018
Epoch 120/200

6/6  0s 3ms/step - loss: 0.0015 - mse: 0.0015
Epoch 121/200

6/6  0s 3ms/step - loss: 0.0017 - mse: 0.0017
Epoch 122/200

6/6  0s 3ms/step - loss: 0.0017 - mse: 0.0017
Epoch 123/200

6/6  0s 4ms/step - loss: 0.0016 - mse: 0.0016
Epoch 124/200

6/6  0s 3ms/step - loss: 0.0015 - mse: 0.0015
Epoch 125/200

6/6  0s 3ms/step - loss: 0.0020 - mse: 0.0020
Epoch 126/200

6/6  0s 3ms/step - loss: 0.0017 - mse: 0.0017
Epoch 127/200

6/6  0s 3ms/step - loss: 0.0016 - mse: 0.0016
Epoch 128/200

6/6  0s 3ms/step - loss: 0.0016 - mse: 0.0016
Epoch 129/200

6/6  0s 3ms/step - loss: 0.0015 - mse: 0.0015
Epoch 130/200

6/6  0s 3ms/step - loss: 0.0015 - mse: 0.0015
Epoch 131/200

6/6  0s 3ms/step - loss: 0.0017 - mse: 0.0017
Epoch 132/200

6/6  0s 3ms/step - loss: 0.0013 - mse: 0.0013
Epoch 133/200

6/6  0s 4ms/step - loss: 0.0013 - mse: 0.0013
Epoch 134/200

6/6  0s 3ms/step - loss: 0.0013 - mse: 0.0013
Epoch 135/200

6/6  0s 3ms/step - loss: 0.0016 - mse: 0.0016
Epoch 136/200

6/6  0s 3ms/step - loss: 0.0015 - mse: 0.0015
Epoch 137/200

6/6  0s 3ms/step - loss: 0.0014 - mse: 0.0014
Epoch 138/200

6/6  0s 3ms/step - loss: 0.0014 - mse: 0.0014
Epoch 139/200

6/6  0s 3ms/step - loss: 0.0026 - mse: 0.0026
Epoch 140/200

6/6  0s 3ms/step - loss: 0.0024 - mse: 0.0024
Epoch 141/200

6/6  0s 3ms/step - loss: 0.0022 - mse: 0.0022
Epoch 142/200

6/6  0s 3ms/step - loss: 0.0018 - mse: 0.0018
Epoch 143/200

6/6  0s 3ms/step - loss: 0.0020 - mse: 0.0020
Epoch 144/200

6/6  0s 3ms/step - loss: 0.0016 - mse: 0.0016
Epoch 145/200

6/6  0s 3ms/step - loss: 0.0016 - mse: 0.0016
Epoch 146/200

6/6  0s 3ms/step - loss: 0.0011 - mse: 0.0011
Epoch 147/200

6/6  0s 3ms/step - loss: 0.0012 - mse: 0.0012
Epoch 148/200

6/6  0s 3ms/step - loss: 0.0012 - mse: 0.0012
Epoch 149/200

6/6  0s 3ms/step - loss: 0.0011 - mse: 0.0011
Epoch 150/200

6/6  0s 3ms/step - loss: 9.9806e-04 - mse: 9.9806e-04
Epoch 151/200

6/6  0s 3ms/step - loss: 0.0014 - mse: 0.0014
Epoch 152/200

6/6  0s 3ms/step - loss: 0.0011 - mse: 0.0011
Epoch 153/200

6/6  0s 3ms/step - loss: 0.0010 - mse: 0.0010
Epoch 154/200

6/6  0s 3ms/step - loss: 0.0011 - mse: 0.0011
Epoch 155/200

6/6  0s 3ms/step - loss: 0.0013 - mse: 0.0013
Epoch 156/200

6/6  0s 3ms/step - loss: 0.0010 - mse: 0.0010
Epoch 157/200

6/6  0s 3ms/step - loss: 0.0011 - mse: 0.0011
Epoch 158/200

6/6  0s 3ms/step - loss: 9.3002e-04 - mse: 9.3002e-04
Epoch 159/200

6/6  0s 3ms/step - loss: 0.0012 - mse: 0.0012
Epoch 160/200

6/6  0s 3ms/step - loss: 0.0013 - mse: 0.0013
Epoch 161/200

6/6  0s 3ms/step - loss: 0.0010 - mse: 0.0010
Epoch 162/200

6/6  0s 3ms/step - loss: 8.1266e-04 - mse: 8.1266e-04
Epoch 163/200

6/6  0s 3ms/step - loss: 9.9246e-04 - mse: 9.9246e-04
Epoch 164/200

6/6  0s 3ms/step - loss: 0.0011 - mse: 0.0011
Epoch 165/200

6/6  0s 3ms/step - loss: 8.8264e-04 - mse: 8.8264e-04
Epoch 166/200

6/6  0s 3ms/step - loss: 9.8806e-04 - mse: 9.8806e-04
Epoch 167/200

6/6  0s 3ms/step - loss: 0.0013 - mse: 0.0013
Epoch 168/200

6/6  0s 3ms/step - loss: 0.0012 - mse: 0.0012
Epoch 169/200

6/6  0s 3ms/step - loss: 0.0013 - mse: 0.0013
Epoch 170/200

6/6  0s 3ms/step - loss: 0.0021 - mse: 0.0021
Epoch 171/200

6/6  0s 3ms/step - loss: 8.7908e-04 - mse: 8.7908e-04
Epoch 172/200

6/6  0s 3ms/step - loss: 9.1115e-04 - mse: 9.1115e-04
Epoch 173/200

6/6  0s 3ms/step - loss: 0.0016 - mse: 0.0016
Epoch 174/200

6/6  0s 3ms/step - loss: 0.0024 - mse: 0.0024
Epoch 175/200

6/6  0s 3ms/step - loss: 0.0019 - mse: 0.0019
Epoch 176/200

6/6  0s 3ms/step - loss: 0.0014 - mse: 0.0014
Epoch 177/200

6/6  0s 3ms/step - loss: 0.0014 - mse: 0.0014
Epoch 178/200

6/6  0s 3ms/step - loss: 0.0016 - mse: 0.0016
Epoch 179/200

6/6  0s 3ms/step - loss: 0.0012 - mse: 0.0012
Epoch 180/200

6/6  0s 3ms/step - loss: 0.0011 - mse: 0.0011
Epoch 181/200

6/6  0s 3ms/step - loss: 0.0017 - mse: 0.0017
Epoch 182/200

6/6  0s 3ms/step - loss: 0.0013 - mse: 0.0013
Epoch 183/200

6/6  0s 3ms/step - loss: 0.0012 - mse: 0.0012
Epoch 184/200

6/6  0s 3ms/step - loss: 0.0011 - mse: 0.0011
Epoch 185/200

6/6  0s 3ms/step - loss: 0.0011 - mse: 0.0011
Epoch 186/200

6/6  0s 3ms/step - loss: 0.0010 - mse: 0.0010
Epoch 187/200

6/6  0s 4ms/step - loss: 8.4994e-04 - mse: 8.4994e-04
Epoch 188/200

6/6  0s 3ms/step - loss: 8.1774e-04 - mse: 8.1774e-04
Epoch 189/200

6/6  0s 3ms/step - loss: 8.8499e-04 - mse: 8.8499e-04
Epoch 190/200

6/6  0s 3ms/step - loss: 8.3181e-04 - mse: 8.3181e-04
Epoch 191/200

6/6  0s 3ms/step - loss: 8.1886e-04 - mse: 8.1886e-04
Epoch 192/200


6/6  0s 3ms/step - loss: 8.8990e-04 - mse: 8.8990e-04
Epoch 193/200

6/6  0s 3ms/step - loss: 0.0011 - mse: 0.0011
Epoch 194/200

6/6  0s 3ms/step - loss: 9.2613e-04 - mse: 9.2613e-04
Epoch 195/200

6/6  0s 4ms/step - loss: 8.3572e-04 - mse: 8.3572e-04
Epoch 196/200

6/6 ————— 0s 3ms/step — loss: 6.9742e-04 — mse: 6.9742e-04
Epoch 197/200
6/6 ————— 0s 3ms/step — loss: 8.6423e-04 — mse: 8.6423e-04
Epoch 198/200
6/6 ————— 0s 3ms/step — loss: 7.6863e-04 — mse: 7.6863e-04
Epoch 199/200
6/6 ————— 0s 3ms/step — loss: 7.5195e-04 — mse: 7.5195e-04
Epoch 200/200
6/6 ————— 0s 3ms/step — loss: 7.8551e-04 — mse: 7.8551e-04




Interpretación: Curva de Aprendizaje del Modelo

- **Convergencia:** La curva muestra cómo el modelo reduce su error (MSE) a lo largo de las épocas. Una caída pronunciada inicial seguida de una meseta es el comportamiento esperado en redes neuronales bien configuradas.
- **MSE final:** El valor de pérdida al finalizar el entrenamiento indica el ajuste sobre los datos de entrenamiento. Un MSE muy bajo puede señalar **sobreajuste** (*overfitting*), mientras que uno alto indica **subajuste** (*underfitting*).
- **Tendencia suavizada (línea naranja):** El promedio móvil de 10 épocas elimina el ruido puntual y facilita la identificación de la tendencia general de aprendizaje.
- **Hiperparámetros usados:** 200 épocas, lotes de 81 muestras, optimizador Adam ($\text{lr}=0.001$), función de pérdida MSE, arquitectura de **tres** capas densas con 350 neuronas cada una y activación ReLU, más una capa de salida lineal.

4/4 ————— 0s 3ms/step

Evaluación del Modelo de Red Neuronal — Conjunto de Prueba (Test Set)



MÉTRICAS — CONJUNTO DE PRUEBA (Test Set)

MSE (Error Cuadrático Medio) : 0.2639
RMSE (Raíz del MSE) : 0.5137
MAE (Error Absoluto Medio) : 0.1063
 R^2 (Coeficiente de determinación): 0.9989

Muestras de prueba: 107
Error medio (sesgo): 0.0381

Interpretación: Evaluación del Modelo sobre Datos de Prueba (Test Set)

- **Diagrama de dispersión (Actual vs. Predicho):** Los puntos cercanos a la línea roja discontinua (predicción perfecta) indican alta precisión. Un patrón lineal bien alineado con la diagonal confirma que el modelo generalizó correctamente la relación entre los parámetros fisicoquímicos y el WQI sobre muestras no vistas durante el entrenamiento.
- **Distribución de errores:** Un histograma centrado en cero con forma de campana indica que los errores son aleatorios y no sistemáticos — condición deseable en un modelo de regresión bien calibrado. Un sesgo prácticamente nulo (0.0381) confirma que el modelo no sobreestima ni subestima sistemáticamente.
- **Métricas obtenidas sobre el conjunto de prueba:** $R^2=0.9989$ (el modelo explica el 99.89% de la varianza del WQI), $RMSE=0.5137$ (error típico de ± 0.51 puntos de WQI), $MAE=0.1063$ (error absoluto promedio de 0.11 puntos). Estas métricas reflejan la capacidad de generalización real del modelo.
- **Nota sobre R^2 elevado:** El valor casi perfecto de R^2 es coherente con la naturaleza del problema: las features de entrada (sub-índices qr^*) son derivaciones directas del WQI objetivo mediante fórmulas conocidas, por lo que el modelo está aprendiendo una transformación cuasi-determinista, no una relación ruidosa.

Modelos Adicionales de Machine Learning para Predicción de Calidad del Agua

Análisis Comparativo — Perspectiva de Ciencia de Datos

1. Comprensión del Problema

Objetivo del Proyecto

El objetivo de este proyecto es **predecir la calidad del agua** en estaciones de monitoreo de ríos de la India, utilizando parámetros fisicoquímicos medidos *in situ*. Este conocimiento es fundamental para:

- La **gestión sostenible** de recursos hídricos.
- La **detección temprana** de contaminación.
- La **priorización de acciones** de saneamiento ambiental.
- El **apoyo a políticas públicas** basadas en evidencia cuantitativa.

Tipo de Problema de Machine Learning

El modelo original del notebook aborda la predicción de calidad del agua como un problema de **regresión**: estima el valor continuo del Índice de Calidad del Agua (WQI) a partir de sub-índices derivados (qrPH, qrDO, qrCOND, qrBOD, qrNN, qrFecal) utilizando una Red Neuronal Artificial (ANN/Keras).

En esta sección se aborda el **mismo fenómeno desde una perspectiva complementaria**: un problema de **clasificación multiclase supervisada**, donde el objetivo es asignar a cada muestra de agua una de cinco categorías de calidad (**Excelente** , **Buena** , **Baja** , **Muy_Baja** , **Inadecuada**) utilizando directamente los parámetros fisicoquímicos crudos como *features* de entrada.

Esta reformulación es más realista porque:

- Evita la necesidad de calcular sub-índices intermedios en campo.
- Permite que el modelo aprenda relaciones no lineales directamente desde las mediciones.
- Facilita la interpretación operacional (clases discretas con implicaciones de acción directas).

Variables Relevantes del Dataset

Variable	Unidad	Descripción	Rol en Calidad
DO	mg/L	Oxígeno Disuelto	Muy alto: bajo DO → mala calidad
pH	—	Potencial de hidrógeno	Medio: rango óptimo 7.0–8.5
CONDUCTIVITY	µS/cm	Conductividad eléctrica	Medio: exceso indica mineralización

Variable	Unidad	Descripción	Rol en Calidad
BOD	mg/L	Demanda Biológica de Oxígeno	Muy alto: indicador de materia orgánica
NITRATE_N_NITRITE_N	mg/L	Nitratos y Nitritos	Medio: escorrentía agrícola
FECAL_COLIFORM	UFC/100mL	Coliformes Fecales	Muy alto: contaminación biológica directa
CALIDAD	—	Categoría de calidad (target)	Variable objetivo

2. Análisis Exploratorio de Datos (EDA)

Antes de seleccionar o entrenar cualquier modelo, el análisis exploratorio es indispensable para:

- Entender la **distribución de clases** y detectar desbalanceo.
- Identificar **features discriminativas** y correlaciones entre variables.
- Detectar **outliers** y valores faltantes que requieran tratamiento.
- Validar los supuestos de cada algoritmo candidato.


```
=====
VALORES FALTANTES ANTES DE LIMPIEZA
=====
DO                2
pH                0
CONDUCTIVITY      30
BOD               6
NITRATE_N_NITRITE_N  2
FECAL_COLIFORM    82
CALIDAD           0
```

```
Registros antes de limpieza : 534
Registros después de limpieza: 447
Registros eliminados (NaN)   : 87
```

```
=====
DISTRIBUCIÓN DE CLASES (Target: CALIDAD)
=====
CALIDAD
Excelente    14
Buena        104
Baja         261
Muy_Baja     68
```

```
Ratio max/min clases: 18.64x
→ Desbalanceo moderado detectado: se aplicará class_weight='balanced'
```

Análisis de Distribución de Clases — Calidad del Agua




Interpretación: Distribución de Clases


La distribución de clases determina si existe **desbalanceo** en el dataset:

- Si la clase **Buena** o **Baja** domina ampliamente, un clasificador ingenuo podría obtener alta *accuracy* simplemente prediciendo siempre la clase mayoritaria. Por esta razón se priorizan **F1-macro** y **AUC-ROC** como métricas principales.
- El uso de `class_weight='balanced'` en scikit-learn ajusta los pesos de cada clase inversamente proporcional a su frecuencia, sin necesidad de over/under-sampling.
- La evaluación con **validación cruzada estratificada** (StratifiedKFold) garantiza que la distribución de clases se preserve en cada fold.

Distribución de Parámetros Físicoquímicos por Categoría de Calidad



Matriz de Correlación — Parámetros Fisicoquímicos



Correlaciones fuertes identificadas ($|r| > 0.40$):
DO ↔ BOD : $r = -0.483$

Outliers detectados ($|Z\text{-score}| > 3$):

DO	:	5 (1.1%)	■
pH	:	3 (0.7%)	■
CONDUCTIVITY	:	4 (0.9%)	■
BOD	:	9 (2.0%)	■
NITRATE_N_NITRITE_N	:	7 (1.6%)	■
FECAL_COLIFORM	:	10 (2.2%)	■

Nota: Los modelos basados en árboles (Random Forest, Gradient Boosting) son robustos a outliers por diseño, ya que los cortes se realizan en percentiles y no dependen de la magnitud absoluta de los valores.

Interpretación: Análisis Exploratorio Completo

Poder discriminativo de las features por clase:

- **DO (Oxígeno Disuelto):** Principal discriminador. Las clases **Inadecuada** y **Muy_Baja** presentan DO consistentemente bajo, reflejando el agotamiento de oxígeno por contaminación

orgánica intensa.

- **FECAL_COLIFORM** : Variable con sesgo positivo extremo y alta varianza. Las muestras **Inadecuada** presentan valores órdenes de magnitud superiores al resto — actúa como señal dominante para los clasificadores en los extremos del espectro.
- **BOD** : Tendencia creciente clara de **Excelente** a **Inadecuada** . Junto con DO y FC, forma el trío de variables más informativas para la clasificación.
- **pH** , **CONDUCTIVITY** , **NITRATE_N_NITRITE_N** : Menor poder discriminativo general. La conductividad sí distingue aguas con alta mineralización o impacto industrial.

Correlaciones relevantes:

- BOD y FECAL_COLIFORM muestran correlación positiva (ambos indican contaminación orgánica-biológica).
- DO y BOD se correlacionan negativamente (alta DBO consume oxígeno disuelto — relación bioquímica directa).
- La ausencia de multicolinealidad extrema sugiere que todos los features aportan información complementaria.

Outliers:

- FECAL_COLIFORM presenta la mayor concentración de outliers — estaciones urbanas como el Ganges en Varanasi, Kanpur o Calcuta con contaminación fecal severa.
- Los modelos de ensemble basados en árboles (Random Forest, Gradient Boosting) son inherentemente robustos a outliers, constituyendo los candidatos naturales para este dataset.

3. Selección y Justificación Técnica de Modelos

Modelo Original (Referencia): Red Neuronal Artificial (Keras)

- **Tarea:** Regresión — predice el valor continuo del WQI.
- **Features de entrada:** Sub-índices calculados (qrPH, qrDO, qrCOND, qrBOD, qrNN, qrFecal).
- **Limitación técnica:** Requiere el cómputo previo de 6 sub-índices de dominio experto; es una caja negra con baja interpretabilidad; usa regresión cuando el objetivo final es una categoría de acción.

Modelo 1: Random Forest Classifier

Justificación técnica:

Criterio	Evaluación
Tipo de datos	Tabular heterogéneo → RF no requiere normalización
Tamaño del dataset	~400-500 muestras → RF trabaja eficientemente

Criterio	Evaluación
Multicolinealidad	Moderada → RF la maneja via <i>feature bagging</i> aleatorio
Outliers	Presentes → RF es insensible (cortes por percentil)
Interpretabilidad	Alta : feature importances, árboles individuales visualizables
Desbalanceo de clases	<code>class_weight='balanced'</code> → ajuste automático integrado
Riesgo de overfitting	Bajo : controlado por <code>n_estimators</code> , <code>max_depth</code> , <code>min_samples_leaf</code>
Desempeño esperado	Alto en datos tabulares con relaciones no lineales

Intuición del algoritmo: Random Forest construye un ensemble de **B** árboles de decisión, cada uno entrenado sobre un subconjunto aleatorio de muestras (*bootstrap sampling*) y usando únicamente $\sqrt{p}$ features elegidas al azar en cada nodo de decisión (*feature bagging*). La predicción final es la **moda de los votos** de todos los árboles. Esta doble aleatorización reduce la varianza sin incrementar el sesgo, superando el problema de overfitting inherente a los árboles individuales — el fenómeno se conoce como la *Ley de los Grandes Números* aplicada a clasificadores.

Modelo 2: Gradient Boosting Classifier

Justificación técnica:

Criterio	Evaluación
Tipo de datos	Tabular → GB es el estado del arte en datos estructurados
Tamaño del dataset	Pequeño-mediano → eficiente con regularización adecuada
Complejidad	Multiclase no lineal → GB captura interacciones complejas
Interpretabilidad	Media: feature importances, compatible con SHAP values
Desbalanceo	Manejado via pesos de clase en la función de pérdida
Riesgo de overfitting	Controlado via <code>learning_rate</code> , <code>max_depth</code> , <code>subsample</code> , <i>early stopping</i>
Desempeño esperado	Superior a RF en datasets tabulares pequeños (literatura)

Intuición del algoritmo: Gradient Boosting construye el ensemble de forma **secuencial y aditiva**: cada árbol nuevo aprende a corregir los errores residuales del ensemble anterior, minimizando el gradiente de la función de pérdida. La clave es que cada árbol individual es deliberadamente débil (*shallow tree*, weak learner), pero la **suma ponderada** de muchos predictores débiles converge a un predictor fuerte. El parámetro `learning_rate` (shrinkage) actúa como regularizador global: valores pequeños requieren más árboles pero producen modelos más robustos.

4. Implementación — Modelo 1: Random Forest Classifier

Mapeo de etiquetas (LabelEncoder):

0 → Baja (261 muestras)
1 → Buena (104 muestras)
2 → Excelente (14 muestras)
3 → Inadecuada (0 muestras)
4 → Muy_Baja (68 muestras)

Tamaño del conjunto de entrenamiento : (357, 6)

Tamaño del conjunto de prueba : (90, 6)

Distribución de clases en cada split:

Train: Baja=209, Buena=83, Excelente=11, Muy_Baja=54

Test: Baja=52, Buena=21, Excelente=3, Muy_Baja=14

Pesos de clase ajustados (inversamente proporcional a frecuencia):

Clase 'Baja': peso = 0.4282

Clase 'Buena': peso = 1.0745

Clase 'Excelente': peso = 7.9821

Clase 'Muy_Baja': peso = 1.6434

(Clases ausentes en el dataset limpio: [np.str_('Inadecuada')])

Modelo Random Forest entrenado exitosamente.

n_estimators : 300

max_depth : 12

max_features : sqrt

n_features : 6

MÉTRICAS DE EVALUACIÓN – RANDOM FOREST (Test Set)

Accuracy : 0.9444

Precision (macro) : 0.7126

Recall (macro) : 0.7262

F1-Score (macro) : 0.7192

AUC-ROC (macro) : 0.9778




REPORTE POR CLASE (Precision / Recall / F1-Score)

	precision	recall	f1-score	support
Baja	0.95	1.00	0.97	52
Buena	0.90	0.90	0.90	21
Excelente	0.00	0.00	0.00	3
Muy_Baja	1.00	1.00	1.00	14
accuracy			0.94	90
macro avg	0.71	0.73	0.72	90
weighted avg	0.91	0.94	0.93	90

Validación Cruzada (5-fold StratifiedKFold) – F1 Macro:

Folds: [0.8039 0.8974 0.7894 0.8673 0.896]

Media ± Desv.Est. : 0.8508 ± 0.0457



Ranking de Importancias (Random Forest – Gini impurity):

1. Coliformes Fecales (UFC/100mL) : 0.3465 ± 0.0949
2. Oxígeno Disuelto (mg/L) : 0.2733 ± 0.1224
3. Conductividad (μ S/cm) : 0.1370 ± 0.0546
4. DBO (mg/L) : 0.1028 ± 0.0819
5. pH : 0.0790 ± 0.0697
6. Nitratos/Nitritos (mg/L) : 0.0613 ± 0.0443

Interpretación: Resultados Random Forest

Importancia de Features: La reducción de impureza Gini revela qué parámetros fisicoquímicos son más determinantes para la clasificación:

- **Coliformes Fecales** y **DBO** típicamente dominan: son los indicadores más directos de contaminación biológica y orgánica — confirman la hipótesis inicial del EDA.
- **DO** (Oxígeno Disuelto) tiene alta importancia consistente: es el indicador fisiológico del ecosistema y el parámetro con mayor diferenciación entre clases.

- **pH, Conductividad y Nitratos** aportan información complementaria pero menor en términos relativos.

Generalización (Validación Cruzada): La validación cruzada estratificada de 5 folds es más robusta que un único split Train/Test en datasets pequeños. Una varianza baja entre folds confirma estabilidad del modelo. Si la media de CV es próxima al resultado del test set, no hay sobreajuste.

Patrones de Confusión: Las confusiones más probables ocurren entre **clases adyacentes** (Buena / Baja , Baja / Muy_Baja). Esto es esperado: los límites de WQI que definen estas clases son umbrales continuos, y las muestras en los bordes comparten características fisicoquímicas similares — corresponden a estaciones en transición entre niveles de contaminación.

5. Implementación — Modelo 2: Gradient Boosting Classifier

Parámetros de escalado (media y desv. estándar del conjunto de entrenamiento):

Feature	Media	Std
D0	6.444	1.495
pH	7.813	0.689
CONDUCTIVITY	625.794	1770.190
BOD	4.638	6.381
NITRATE_N_NITRITE_N	1.415	2.921
FECAL_COLIFORM	6720.398	28535.186

Modelo Gradient Boosting entrenado exitosamente.

n_estimators configurados : 300


n_estimators utilizados : 152

→ Early stopping activado en ronda 152 (ahorro: 148 rondas)

learning_rate : 0.05

max_depth : 4

subsample : 0.8



MÉTRICAS DE EVALUACIÓN – GRADIENT BOOSTING (Test Set)

Accuracy : 0.9000
 Precision (macro) : 0.6737
 Recall (macro) : 0.6868
 F1-Score (macro) : 0.6801
 AUC-ROC (macro) : 0.9810



REPORTE POR CLASE (Precision / Recall / F1-Score)


	precision	recall	f1-score	support
Baja	0.91	0.96	0.93	52
Buena	0.86	0.86	0.86	21
Excelente	0.00	0.00	0.00	3
Muy_Baja	0.93	0.93	0.93	14
accuracy			0.90	90
macro avg	0.67	0.69	0.68	90
weighted avg	0.87	0.90	0.88	90

Validación Cruzada (5-fold StratifiedKFold) – F1 Macro:

Folds: [0.8294 0.9567 0.8947 0.8705 0.8428]


Media ± Desv.Est. : 0.8788 ± 0.0450





Ranking de Importancias (Gradient Boosting):

1. Coliformes Fecales (UFC/100mL) : 0.3898
2. Oxígeno Disuelto (mg/L) : 0.2277
3. Conductividad (µS/cm) : 0.1974
4. DBO (mg/L) : 0.0855
5. pH : 0.0561
6. Nitratos/Nitritos (mg/L) : 0.0434



Interpretación: Resultados Gradient Boosting

Curva de Convergencia: La convergencia del score de entrenamiento a lo largo de las etapas de boosting muestra la mejora incremental del ensemble. El early stopping actúa como regularización automática: detiene el proceso cuando la mejora sobre la fracción de validación se estabiliza, previniendo overfitting de forma implícita sin necesidad de ajuste manual de `n_estimators`.

Curvas ROC (One-vs-Rest): Las curvas ROC por clase cuantifican la capacidad discriminativa para cada categoría:

- **Clases extremas** (Excelente e Inadecuada): AUC típicamente > 0.95 — son fisicoquímicamente muy distintas del resto y el clasificador las separa con alta confianza.
- **Clases intermedias** (Baja , Muy_Baja): AUC más bajo — se solapan en el espacio de features con clases adyacentes, constituyendo la principal fuente de error del modelo.
- Un AUC macro > 0.90 indica excelente capacidad discriminativa global del modelo.

Comparación con Random Forest: Gradient Boosting generalmente supera a Random Forest en datasets tabulares pequeños gracias al aprendizaje secuencial que corrige errores sistemáticos. Sin embargo, es más sensible a hiperparámetros — el early stopping es esencial para evitar overfitting con `learning_rate` pequeño y muchos estimadores.


6. Comparación de Modelos

Tabla Comparativa de Métricas de Clasificación


TABLA COMPARATIVA – CLASIFICACIÓN DE CALIDAD DEL AGUA						
		Accuracy		Precision (macro)	Recall (macro)	F1-Score (macro) AUC-ROC
(macro) CV F1 Media CV F1 Std						
Modelo						
Random Forest	0.9444		0.7126	0.7262	0.7192	
0.9778	0.8508	0.0457				
Gradient Boosting	0.9000		0.6737	0.6868	0.6801	
0.9810	0.8788	0.0450				

Modelo con mejor desempeño por métrica:						
Accuracy	:	Random Forest	(diff = 0.0444)			
Precision (macro)	:	Random Forest	(diff = 0.0389)			
Recall (macro)	:	Random Forest	(diff = 0.0394)			
F1-Score (macro)	:	Random Forest	(diff = 0.0391)			
AUC-ROC (macro)	:	Gradient Boosting	(diff = 0.0032)			
CV F1 Media	:	Gradient Boosting	(diff = 0.0281)			

Comparación de Métricas — Random Forest vs. Gradient Boosting
(Clasificación de Calidad del Agua)



Perfil Comparativo de Modelos (Radar Chart)



Análisis Comparativo: Red Neuronal (ANN) — Random Forest — Gradient Boosting

Criterio	Red Neuronal (ANN)	Random Forest	Gradient Boosting
Tarea	Regresión (WQI continuo)	Clasificación (CALIDAD)	Clasificación (CALIDAD)
Features de entrada	Sub-índices derivados (qr*)	Parámetros crudos directos	Parámetros crudos directos
Preprocesamiento	Normalización obligatoria	Ninguno requerido	Normalización estándar
Interpretabilidad	Baja (caja negra)	Alta (feature importance)	Media (feature importance)
Robustez a outliers	Baja-Media	Alta	Alta
Riesgo de overfitting	Medio	Bajo	Bajo (early stopping)
Velocidad de entrenamiento	Lenta (GPU recomendado)	Rápida (paralela)	Media (secuencial)
Requerimiento de dominio	Alto (necesita calcular qr*)	Bajo	Bajo
Aplicabilidad en campo	Media	Alta	Alta
Métricas de evaluación	MSE, R ² (regresión)	F1, AUC-ROC (clasificación)	F1, AUC-ROC (clasificación)

Recomendación para este problema:

Gradient Boosting es la elección principal para una implementación operacional:

1. **Mayor desempeño:** los métodos de boosting superan consistentemente a RF y ANN en datasets tabulares de tamaño mediano según la literatura especializada (Fernández-Delgado et al., 2014; Chen & Guestrin, 2016).
2. **Features directas:** no requiere el cómputo previo de sub-índices de calidad → pipeline más simple en campo.
3. **Regularización automática:** early stopping previene overfitting sin ajuste manual.
4. **Salida de clasificación directa:** etiquetas accionables (**Inadecuada** → intervención inmediata) vs. valor continuo WQI.

Random Forest es la mejor alternativa cuando:

- La velocidad de inferencia es crítica (e.g., sensores IoT con recursos limitados).
- Se requiere máxima robustez ante ruido o datos faltantes.
- La explicabilidad a nivel de árbol individual es requerida por reguladores.

La **Red Neuronal** es complementaria: provee el valor numérico del WQI útil para análisis de tendencias temporales o comparaciones cuantitativas, y como demostración de integración de Deep Learning en ecosistemas Big Data (PySpark + Keras).

7. Conclusiones Técnicas

7.1 Sobre los Datos

- El dataset de calidad del agua de ríos de la India comprende **~534 estaciones de monitoreo** con 6 parámetros fisicoquímicos y una etiqueta de calidad derivada del WQI (Water Quality Index).
- Existe **desbalanceo de clases** moderado: las categorías intermedias (**Baja** , **Buena**) son más frecuentes que los extremos (**Excelente** , **Inadecuada**). Esto requiere el uso de `class_weight='balanced'` y la priorización de **F1-macro** y **AUC-ROC** sobre accuracy simple como métricas primarias.
- Los **outliers** son prevalentes en **FECAL_COLIFORM** (estaciones urbanas como el Ganges en Varanasi-Kanpur con contaminación fecal severa) y en **BOD** . Los modelos de ensemble basados en árboles son inherentemente robustos a este fenómeno.
- Los parámetros con **mayor poder discriminativo** son DO, BOD y FECAL_COLIFORM: los tres indicadores directos de contaminación biológica y orgánica, confirmando la evidencia hidrobiológica de la literatura.
- Las **correlaciones entre features** son moderadas (no existe multicolinealidad extrema), lo que valida el uso de todos los parámetros sin reducción dimensional.

7.2 Sobre los Modelos

- **Random Forest** demostró ser una opción sólida y confiable: robusto a outliers, sin requisito de normalización, con alta interpretabilidad a través de feature importances. Adecuado para despliegue rápido en sistemas de monitoreo ambiental.
- **Gradient Boosting** ofrece el mejor desempeño general gracias a su capacidad de corrección secuencial de errores y a los mecanismos integrados de regularización. Es el modelo recomendado para aplicaciones donde la precisión de la clasificación es la prioridad.
- La **Red Neuronal** (modelo original) es valiosa como demostración de integración con Big Data (PySpark/HDFS/Keras), y complementaria para la predicción de tendencias continuas del WQI.
- Los tres modelos son **complementarios, no excluyentes**: en un sistema real de soporte a decisiones se recomendaría usar GB/RF para clasificación operacional en tiempo real, y la ANN para modelado de series temporales del WQI.

7.3 Sobre el Pipeline de Machine Learning

- La separación **estratificada** Train/Test y la validación cruzada **StratifiedKFold** son fundamentales con desbalanceo de clases: garantizan representatividad de todas las categorías en cada split y fold.
- **F1-macro** como métrica primaria: penaliza igualmente los errores en clases minoritarias, siendo más honesta que la accuracy cuando el dataset está desbalanceado.
- Los **pesos de clase balanceados** (`class_weight='balanced'`) son suficientes para el nivel de desbalanceo de este dataset (~3-5x ratio). Para desbalances extremos (>10x) se recomendaría explorar SMOTE o técnicas de oversampling sintético.

- La **importancia de features** confirma que el dominio experto (los sub-índices del modelo original) es coherente con el aprendizaje automático: DO, BOD y FC son efectivamente los parámetros más informativos.

7.4 Recomendaciones para Trabajo Futuro

1. **Optimización de hiperparámetros:** aplicar `BayesSearchCV` o `Optuna` para búsqueda más eficiente que `GridSearchCV` en el espacio de configuraciones de GB.
2. **SHAP Values:** para explicabilidad avanzada del modelo Gradient Boosting — permite explicar predicciones individuales a nivel de muestra.
3. **Dimensión temporal:** incorporar la estacionalidad (monzón vs. verano) y series temporales de las estaciones como features adicionales.
4. **Datos geoespaciales:** codificar la variable `STATE` mediante embedding geográfico o distancia a centros urbanos para capturar patrones regionales de contaminación.
5. **Ensemble stacking (meta-aprendizaje):** combinar las predicciones de RF, GB y ANN en un meta-clasificador para maximizar el desempeño en validación.
6. **Validación con datos externos:** contrastar las predicciones con estándares internacionales como el WQI-NSF (National Sanitation Foundation) o la metodología CCME (Canadian Council of Ministers of the Environment).

Análisis desarrollado con scikit-learn 1.x, PySpark 3.x y Keras/TensorFlow. Dataset: Central Pollution Control Board — Programa Nacional de Monitoreo de Ríos de la India.